

Pipeline de Prevención de Fraude - Documentación Técnica

Candidato: Jonathan Vladimir Montes Rodriguez **Fecha:** 23 de junio de 2026

1. Introducción

Este notebook detalla el diseño y la implementación de un pipeline ETL (Extracción, Transformación y Carga) para el procesamiento de transacciones bancarias, integrando una lógica de detección de anomalías de gasto.

La solución cumple con tres objetivos principales:

1. **Calidad de Datos:** Limpieza y normalización de registros crudos.
2. **Persistencia:** Carga centralizada en PostgreSQL (Supabase).
3. **Analítica:** Detección de patrones de fraude mediante SQL Avanzado (Window Functions).

2. Fase 1: ETL (Pandas)

La arquitectura de procesamiento se basa en **Pandas** por su capacidad de vectorización, garantizando eficiencia.

- **Deduplicación:** Se priorizó el `id_transaccion` como llave única, manteniendo solo la primera ocurrencia.
- **Imputación de Nulos:** La regla de negocio de imputar `0.0` en transacciones rechazadas con monto nulo asegura la trazabilidad del intento de fraude sin sesgar promedios financieros.
- **Ingeniería de Características:** Se creó la columna booleana `es_monto_inusual`, optimizando la consulta posterior.

```
In [1]: import pandas as pd
# Simulamos la carga para verificar la estructura
df = pd.read_csv('../data/transacciones_diarias.csv')
df_clean = df.drop_duplicates(subset=['id_transaccion'], keep='first')
print(f"Registros procesados: {len(df_clean)}")
print(df_clean.head())
```

Registros procesados: 122

	id_transaccion	id_cliente	fecha_hora	monto_usd	tipo_comercio	\
0	T-001	C-101	2026-06-18 08:00:00	50.0	nacional	
2	T-002	C-102	2026-06-18 08:15:00	NaN	internacional	
3	T-003	C-103	2026-06-18 08:20:00	120.5	nacional	
4	T-004	C-104	2026-06-18 08:45:00	1850.0	internacional	
5	T-005	C-101	2026-06-18 09:30:00	350.0	internacional	

	estado_transaccion
0	aprobada
2	rechazada
3	pendiente
4	aprobada
5	aprobada

3. Fase 2: Análisis SQL de Anomalías

Para la detección de fraude (transacciones > 5x la anterior), delegamos la lógica al motor de base de datos.

- **CTE (Common Table Expression):** Aísla las transacciones aprobadas antes de aplicar la función `LAG()`.
- **Window Functions:** La función `LAG()` permite comparar cronológicamente la transacción actual con la anterior por cliente (`PARTITION BY id_cliente`), minimizando el uso de memoria en la aplicación.

id_cliente	id_transaccion	fecha_hora	monto_actual	monto_anterior
C-101	T-005	2026-06-18 09:30:00	350.00	50.00
C-101	T-117	2026-06-18 19:15:00	80.00	10.00
C-120	T-024	2026-06-18 11:15:00	150.00	25.00
C-146	T-051	2026-06-18 13:50:00	100.00	15.00

Análisis de anomalías (Consulta SQL)

```
WITH TransaccionesAprobadas AS (  
    SELECT  
        id_cliente, monto_usd, fecha_hora,  
        LAG(monto_usd) OVER (PARTITION BY id_cliente ORDER BY  
fecha_hora) as monto_anterior  
    FROM transacciones  
    WHERE estado_transaccion = 'aprobada'  
)  
SELECT * FROM TransaccionesAprobadas  
WHERE monto_usd >= (monto_anterior * 5);
```

4. Fase 3: Orquestación (Airflow)

El flujo fue diseñado para ejecutarse diariamente a las 11:30 PM.

- **Dependencia:** El operador `tarea_analitica` solo se activa si `tarea_etl` finaliza con estado exitoso.
- **Resiliencia:** Se configuraron políticas de reintento (`retries: 1`) ante posibles fallos intermitentes de red con la base de datos Supabase.

5. Conclusiones y Futuros Pasos

Este pipeline MVP proporciona una base sólida para la prevención de fraude.

- **Próximas mejoras:**
 - Implementar **Validación de Esquema** con `Great Expectations` .
 - Configurar **alertas en tiempo real** (Slack/Email) en Airflow ante anomalías detectadas.
 - Migrar los secretos de conexión a un **Secret Manager** (AWS/GCP).

Repositorio del Proyecto

Para revisar el código fuente, la estructura del proyecto y la documentación completa, puedes acceder al repositorio oficial en GitHub:

Acceder al Repositorio: [pipeline_fraude_mvp](#)

Este proyecto fue desarrollado como parte de una evaluación técnica, aplicando principios de ingeniería de datos, orquestación de flujos y análisis de integridad de datos.

In []: